

TEXT REUSE DETECTOR

2026

Irene Cipparone

Panoramica

Carica o incolla un testo originale e un testo da controllare. Il sistema stima quanto i due testi siano correlati e spiega perché.

Obiettivi

Identificare automaticamente quanto e come due testi sono correlati: il secondo testo potrebbe essere stato copiato, leggermente modificato, parafrasato o riscritto.

Utenti target

- team di content creation
- editor
- docenti
- ricercatori
- team di comunicazione

Input

Due testi:

- testo originale
- testo da controllare

Output

Il sistema restituisce:

- percentuale di similarità (media tra Jaccard e Cosine)
- classificazione (tipologia di riuso)
- parole condivise
- spiegazione

Metodi

- Preprocessing (pulizia, normalizzazione, tokenizzazione)
- Calcolo Jaccard Similarity 1-gram
- Calcolo Cosine Similarity TF-IDF 1-gram

Pipeline

INPUT

Testo A + Testo B



PREPROCESSING

normalizzazione

tokenizzazione

rimozione stopword



RAPPRESENTAZIONE

unigrammi



SIMILARITY ENGINE

└─ Jaccard

└─ Cosine TF-IDF



OUTPUT

percentuale di similarità



INTERPRETAZIONE

parole condivise

error analysis