

TEXT REUSE DETECTOR

2026

Irene Cipparone

Panoramica

TEXT REUSE DETECTOR è un prototipo NLP per analizzare il grado di similarità tra due testi e fornire un'interpretazione del risultato.

L'utente fornisce un testo originale (Text A) e un testo da controllare (Text B). Il sistema calcola due diverse misure di similarità lessicale e le combina in un unico punteggio complessivo, fornendo inoltre evidenze linguistiche utili a interpretare il risultato.

Il progetto non mira a formulare un giudizio assoluto di plagio, ma a fornire un'indicazione quantitativa e interpretabile della relazione tra due testi.

Obiettivi

L'obiettivo è identificare automaticamente quanto due testi siano linguisticamente simili e analizzare come il livello di similarità varia in presenza di diverse forme di riuso testuale.

In particolare, il progetto considera i seguenti scenari:

- testo non correlato;
- copia letterale;
- near-copy;
- sostituzione lessicale tramite sinonimi;
- riformulazione sintattica;
- parafrasi;
- parafrasi generata da un LLM.

L'analisi permette di valutare quanto le diverse trasformazioni preservino la similarità lessicale tra il testo originale e quello modificato.

Utenti target

Il prototipo è pensato per potenziali utilizzi da parte di:

- team di content creation;
- editor;
- docenti;
- ricercatori;
- team di comunicazione.

Input

Il sistema riceve due testi:

- Text A: testo originale;
- Text B: testo da controllare.

Per la fase sperimentale, i testi sono stati ricavati da un dataset contenente esempi di diverse tipologie controllate di riuso testuale.

Output

Per ogni coppia di testi, il sistema restituisce:

- Jaccard Similarity (%);
- Cosine Similarity TF-IDF (%);
- Overall Similarity (%), calcolata come media delle due misure;

- numero di parole condivise;
- elenco delle parole condivise;
- un profilo qualitativo della similarità;
- una spiegazione della relazione tra le due metriche.

Il sistema mantiene separate le due metriche per rendere il risultato finale più interpretabile.

Metodi

1. Preprocessing

I testi vengono sottoposti a preprocessing linguistico attraverso:

- normalizzazione in lowercase;
- tokenizzazione con spaCy;
- selezione dei token alfabetici;
- lemmatizzazione;
- rimozione delle stopwords.

2. Rappresentazione

I testi preprocessati vengono rappresentati attraverso unigrammi (1-gram).

3. Similarity Engine

Vengono calcolate due misure complementari:

- Jaccard Similarity: Misura la sovrapposizione tra gli insiemi di parole presenti nei due testi;
- Cosine Similarity TF-IDF

I testi vengono rappresentati come vettori TF-IDF basati su unigrammi e confrontati attraverso la cosine similarity.

4. Overall Similarity

Le due misure vengono combinate attraverso una media aritmetica

Il risultato viene espresso come percentuale.

Non viene utilizzata una soglia binaria fissa per stabilire se due testi siano o non siano "plagio". Il punteggio viene invece interpretato insieme alle singole metriche e alle parole condivise.

Interpretazione

L'interpretazione considera sia il livello complessivo di similarità sia la relazione tra Jaccard e Cosine TF-IDF.

In particolare, la differenza tra le due metriche permette di osservare se la similarità è principalmente riconducibile alla sovrapposizione del vocabolario oppure anche alla distribuzione e al peso dei termini nei due testi.

Il sistema produce quindi una spiegazione qualitativa del profilo osservato, mantenendo il risultato interpretabile dal punto di vista linguistico.

Valutazione ed error analysis

La pipeline include una fase di error analysis finalizzata a individuare i casi in cui la similarità lessicale può risultare fuorviante.

In particolare vengono analizzati:

- false positive candidates: testi classificati nel benchmark come non correlati ma caratterizzati da un'elevata similarità;
- false negative candidates: testi appartenenti alle condizioni di riuso ma caratterizzati da una bassa similarità;
- parole condivise nei casi più problematici.

L'analisi consente di valutare non solo le prestazioni numeriche delle metriche, ma anche le possibili ragioni linguistiche alla base dei risultati.

Pipeline

Pipeline

INPUT

Text A + Text B



PREPROCESSING

lowercasing

tokenizzazione

lemmatizzazione

rimozione stopword



RAPPRESENTAZIONE

unigrammi



SIMILARITY ENGINE

└─ Jaccard

└─ Cosine TF-IDF



AGGREGAZIONE

media delle due metriche



OVERALL SIMILARITY

percentuale



INTERPRETAZIONE

parole condivise

profilo di similarità

spiegazione



VALUTAZIONE

condition analysis

error analysis

Risultato atteso

Il progetto mira a realizzare un prototipo semplice, interpretabile e riproducibile per l'analisi del riuso testuale.

L'approccio basato su Jaccard e TF-IDF permette di quantificare la sovrapposizione lessicale, mentre l'analisi delle parole condivise e degli errori permette di interpretare i risultati.

Il confronto tra le diverse condizioni del dataset consente inoltre di studiare come diverse forme di riscrittura influenzino la similarità misurata automaticamente.

Limitazioni

Il sistema si basa principalmente sulla similarità lessicale. Di conseguenza, non è in grado di rappresentare pienamente la similarità semantica tra testi.

In particolare, parafrasi profonde, sostituzioni lessicali e riscritture generate da LLM possono mantenere sostanzialmente invariato il significato modificando però significativamente la forma linguistica.

Per questo motivo, il punteggio prodotto deve essere considerato come un'indicazione quantitativa della similarità, non come una prova definitiva di plagio o di riuso.

Tecnologie

- Python
- pandas
- NumPy

- spaCy
- scikit-learn
- Jupyter / Google Colab

Il preprocessing linguistico utilizza il modello italiano `it_core_news_sm` di spaCy